

ML세션 2주차 문제

범위: 파이썬 머신러닝 완벽 가이드 2장, 6장

1. 사이킷런 라이브러리에서는 Classifier와 Regressor 클래스를 합쳐서 Estimator라고 부른다. (O / X)
2. Stratified K폴드를 사용하는 주된 이유는 데이터셋의 레이블 불균형을 검증 데이터셋이 잘 반영하지 못하도록 하는 경우를 방지하기 위해서이다. (O / X)
3. Stratified K 폴드는 레이블 분포가 불균형한 경우에 유용하며, 지도학습의 전반적인 task에서 학습 데이터셋과 검증 데이터셋의 레이블 분포를 유지하기 위해 사용할 수 있다. (O / X)
4. GridSearchCV의 파라미터 중 refit=True (디폴트)의 의미와 best_estimator_ 속성의 관계에 대한 설명으로 가장 정확한 것은?
 - a. best_estimator_는 교차 검증 과정에서 가장 점수가 높았던 특정 폴드(Fold)의 모델을 저장한 것이다.
 - b. refit=True이면 교차 검증을 수행하지 않고 전체 데이터로만 학습하며, best_estimator_에는 하이퍼 파라미터 튜닝 전의 초기 모델이 저장된다.
 - c. 최적의 파라미터를 찾은 뒤, 입력된 estimator 객체를 해당 파라미터로 전체 학습 데이터 세트에 대해 다시 학습시키고, 그 결과가 best_estimator_에 저장된다.
 - d. refit=True는 단순히 최적 파라미터만 찾겠다는 의미이며, best_estimator_를 사용하려면 사용자가 직접 다시 fit()을 호출해야 한다.
5. Label Encoding을 적용했을 때 예측 성능이 떨어질 가능성이 가장 높은 머신러닝 알고리즘 유형은?
 - a. 숫자 값의 크고 작음에 대한 특성이 작용하여, 특정 값에 가중치가 더 부여되거나 중요하게 인식되어 예측 성능이 떨어질 수 있다.
 - b. 트리 계열 알고리즘에서도 숫자의 순서를 중요도로 인식하므로 레이블 인코딩을 사용해서는 안 된다.
 - c. 문자열 값을 처리하지 못해 오류가 발생한다.
 - d. 변환된 숫자 값들이 0과 1로만 구성되어 정보의 손실이 발생한다
6. 사이킷런의 OneHotEncoder로 변환된 데이터는 희소 행렬(Sparse Matrix) 형태이다. 이를 다시 밀집 행렬(Dense Matrix)로 변환하여 값을 확인하기 위해 사용해야 하는 메서드는?

답:

7. 판다스(Pandas)에서 OneHotEncoder와 유사하게 문자열 카테고리 값을 숫자형 변환 과정 없이 바로 원-핫 인코딩 해주는 API의 이름으로 알맞은 것은?
- a. str.extract()
 - b. value_counts()
 - c. fillna()
 - d. get_dummies()
8. 데이터셋의 전처리 과정에서, 결측값이 존재하는 경우 항상 결측값을 해당 피쳐의 평균값으로 대체해도 된다 (O / X)
9. 머신러닝 모델 구축의 일반적인 프로세스를 교재에 기반하여 올바르게 나열하시오.
- a. 모델 학습
 - b. 데이터 전처리
 - c. 데이터 세트 분리
 - d. 예측 수행
 - e. 평가

답:

10. 차원 축소는 단순히 데이터의 압축(용량 감소)만을 목적으로 하며, 차원이 줄어들면 정보 손실이 발생하여 예측 신뢰도는 무조건 원본 데이터보다 낮아진다. (O / X)
11. PCA(주성분 분석)를 수행하기 위해 입력 데이터의 공분산 행렬(Covariance Matrix)을 생성하면, 이 행렬은 항상 '대칭 행렬(Symmetric Matrix)'이 된다. 따라서 고유벡터를 직교 행렬로, 고유값을 정방 행렬로 대각화할 수 있다. (O / X)
12. LDA는 클래스 간 분산(between-class scatter)과 클래스 내부 분산(within-class scatter)의 비율을 이용하며, 클래스 간 분산은 작게, 클래스 내부 분산은 크게 만드는 축을 찾는다. (O / X)
13. LDA는 비지도 학습 기반의 클러스터링 및 데이터 압축을 위해 사용될 수 있다. (O / X)
14. NMF(Non-Negative Matrix Factorization)에서 원본 행렬 V (4×6)를 W (4×2)와 H (2×6)로 분해했을 때, W 행렬의 각 행(Row)이 의미하는 바로 알맞은 것은?
- a. 클래스 간 분산과 클래스 내 분산의 비율을 나타낸다.
 - b. 각 데이터 포인트의 고유벡터 투영 값을 나타낸다.
 - c. 원본 행(Record, 예: 사용자)에 대해서 잠재 요소(Latent Factor)의 값이 얼마나 되는지(가중치)를 나타낸다.
 - d. 원본 속성(Feature)들이 잠재 요소로 어떻게 구성되어 있는지 나타낸다.

15. 아래 코드를 실행한 결과를 쓰시오.

```
from sklearn.preprocessing import LabelEncoder

items=['TV','Refrigerator','Microwave','Computer','Fan','Fan','Mixer','Mixer']

le=LabelEncoder()

le.fit(items)

print(le.classes_) print(le.transform(items))
```

답: