

문제 번호	정답	관련 근거 및 설명
1	O	$y=Xw$ 형태의 행렬 내적으로 표현이 가능합니다.
2	O	잔차 제곱합(RSS)을 최소화하는 전통적인 회귀 방식을 OLS라고 합니다.
3	X	학습률이 너무 크면 발산하고, 너무 작으면 최적점에 도달하기 어렵습니다.
4	a	$np.dot(X, w1.T) + w0$ 은 입력 피처와 가중치의 내적에 절편을 더하는 표준 코드입니다.
5	O	선형 독립이더라도 두 벡터가 매우 평행하면 회귀 계수가 불안정해지는 다중공선성이 발생합니다.
6	X	다항 회귀는 피처의 변환일 뿐, 가중치(w)에 대해서는 여전히 선형이므로 선형 모델로 학습 가능합니다.
7	X	계수를 0으로 만드는 것은 Lasso(L1)의 특징입니다. Ridge(L2)는 0에 가깝게 줄일 뿐입니다.
8	10개	1, $x_1, x_2, x_3, x_1^2, x_2^2, x_3^2, x_1x_2, x_1x_3, x_2x_3$ 로 총 10개입니다.
9	a	피처의 스케일(단위)이 다르면 규제 페널티(α)가 불공평하게 적용되기 때문입니다.
10	d	타겟값이 한쪽으로 치우친 경우 로그 변환($np.log1p$)을 통해 정규 분포 형태로 보정하는 것이 일반적인 전략입니다.
11	b	degree(차수)가 높아지면 모델이 복잡해져 편향은 낮아지지만 분산은 높아집니다(과적합).
12	d	RMSE는 오차를 제공하므로, MAE보다 훨씬 크다는 것은 큰 오차를 가진 이상치가 있음을 의미합니다.
13	a	진동하거나 학습이 더딘 경우 학습률(learning_rate)을 낮추어 최적점에 수렴하도록 유도해야 합니다.
14	c	릿지 회귀의 α 항은 행렬을 강제로 가역적으로 만들 뿐, 피처들을 직교하게 변환하는 것은 아닙니다.

[9번] :Ridge, Lasso, ElasticNet과 같은 규제 모델은 회귀 계수(w)의 크기를 제어하여 과적합을 방지합니다. 이때 각 피처의 단위(Scale)가 다르면, 값이 큰 피처의 회귀 계수는 상대적으로 작게, 값이 작은 피처의 회귀 계수는 크게 계산될 수 있습니다. 규제 항은 계수의 절대적인 크기에 페널티를 부여하기 때문에, 실제 중요도와 상관없이 단위가 작은 피처가 훨씬 더 큰 페널티를 받게 되는 왜곡이 발생합니다. 따라서 모든 피처가 공정하게 페널티를 받도록 평균 0, 분산 1 등의 표준화 과정이 반드시 선행되어야 합니다.

[10번]:선형 회귀 모델은 데이터가 정규 분포를 따를 때 최적의 성능을 발휘합니다. 타겟값(y)이 오른쪽으로 긴 꼬리를 가진 형태(Right Skewed)라면, 큰 값들이 소수 존재하여 예측 오차를 왜곡시킬 수 있습니다. 이때 로그 변환(log(x+1))을 적용하면 큰 값들은 작게, 작은 값들은 상대적으로 크게 변환되어 분포를 정규 분포에 가깝게(유사하게) 완화해 줍니다.

[14번]

- 릿지 회귀의 회귀 계수를 구하는 정규방정식이 $w_{Ridge} = (X^T X + \alpha I)^{-1} X^T y$ 인 이유

$$J(w) = \underbrace{\|y - Xw\|_2^2}_{\text{MSE (오차)}} + \underbrace{\alpha \|w\|_2^2}_{\text{L2 Penalty}}$$

$$J(w) = (y^T - w^T X^T)(y - Xw) + \alpha w^T w$$

$$J(w) = y^T y - \underbrace{y^T Xw}_{\text{스칼라}} - \underbrace{w^T X^T y}_{\text{스칼라}} + w^T X^T Xw + \alpha w^T w$$

$$J(w) = y^T y - 2w^T X^T y + w^T X^T Xw + \alpha w^T w$$

$$\frac{\partial J}{\partial w} = -2X^T y + 2X^T Xw + 2\alpha w = 0$$

$$X^T Xw + \alpha w = X^T y$$

$$w = (X^T X + \alpha I)^{-1} X^T y$$

- $X^T X$ 의 특징

- 항상 정방행렬이며, 대칭행렬이다 (Square & Symmetric) => 고유값 분해 가능
- 피쳐(Feature) 간의 관계를 담고 있다
- 양의 준정부호 행렬이다 (Positive Semi-Definite, PSD)
- 피쳐의 개수가 데이터의 수보다 많으면($M \ll N$) 역행렬이 존재하지 않는다.

a: 데이터의 개수(\$N\$)보다 피쳐의 개수(\$M\$)가 훨씬 많은 고차원 상황에서는, 연립방정식의 개수보다 미지수가 더 많은 셈이 되어 해가 무수히 많이 존재하게 됩니다. 수학적으로는 행렬 $X^T X$

의 행렬식이 0이 되어 역행렬이 존재하지 않는 '특이 행렬(Singular Matrix)' 상태가 됩니다. 이때 릿지 회귀는 기존 행렬의 대각선 성분에 양수 α 를 강제로 더해주는 방식을 사용합니다. 이렇게 하면 모든 고유값이 0보다 커지게 되어 행렬이 수학적으로 안정화되고, 역행렬이 무조건 존재하게 되어 유일한 해를 구할 수 있게 됩니다.

b: 데이터 간의 상관관계가 매우 높은 다중공선성 문제가 발생하면, 일반적인 OLS는 데이터를 지나치게 과적합하려는 경향을 보입니다. 이 과정에서 회귀 계수들이 10000\$과 -9999처럼 서로 부호는 반대이면서 절대값은 비정상적으로 큰 값으로 발산하게 됩니다. 릿지 회귀는 손실 함수에 가중치들의 제곱합(L2 Norm)을 패널티로 추가하여 이를 해결합니다. 만약 계수가 커지려고 하면 패널티가 급격히 증가하므로, 모델은 손실을 줄이기 위해 계수의 크기를 강제로 0에 가깝게 작게 유지하게 됩니다.

c: 수식에 αI 를 더한다는 것은 행렬 $X^T X$ 의 '대각 성분(=분산)'에만 값을 더해주는 행위입니다. 피쳐 벡터들 간의 사잇각이나 상관관계를 나타내는 '비대각 성분(내적값)'은 α 를 더해도 전혀 변하지 않습니다. 따라서 릿지 회귀를 적용한다고 해서 원래 상관관계가 높았던 피쳐들이 서로 수직(직교)하게 변하거나 데이터의 기하학적 구조가 바뀌는 것은 아닙니다. 피쳐들을 서로 직교하게 만들기 위해서는 지난 시간에 배운 주성분 분석(PCA)과 같은 별도의 차원 축소 기법을 사용해야 합니다.

d: 일반적인 선형 회귀(OLS)는 편향이 0인 '비편향 추정량'이지만, 데이터가 조금만 바뀌어도 결과가 크게 흔들리는 '고분산(High Variance)' 문제를 가지고 있습니다. 릿지 회귀는 α 라는 제약 조건을 추가함으로써, 정답에서 약간 벗어나는 편향을 의도적으로 발생시킵니다. 하지만 이러한 편향을 감수하는 대가로 모델의 분산을 획기적으로 줄여주게 됩니다. 결과적으로 편향과 분산을 합친 전체 예측 오차(MSE)의 크기는 OLS보다 릿지 회귀가 더 작아지게 되어, 예측 모델로서 더 좋은 성능을 내게 됩니다.