

ML세션 4주차 문제

범위: 파이썬 머신러닝 완벽 가이드 3,4장

1. 데이터의 클래스 분포가 불균형한 경우, 모델의 성능을 평가할 때 '정확도(Accuracy)' 지표만 사용하는 것은 부적절할 수 있다. (O / X)
2. 실제 Positive인 데이터(예: 암 환자)를 Negative(예: 정상)로 잘못 판단하면 생명에 위험이 생기는 등 큰 문제가 발생하는 경우, 가장 중요하게 고려해야 할 평가 지표는 정밀도(Precision)이다. (O / X)
3. 부스팅(Boosting) 알고리즘은 편향을 줄이는 데 효과적이지만, 학습 데이터에 있는 이상치에 대해서는 매우 취약하여 과적합되기 쉽다. (O / X)
4. 모든 데이터를 Positive로 예측하면 FN이 0이 되므로 ()은/는 100%가 된다. 빈칸에 들어갈 말은?

답:

5. F1 스코어(Score)는 정밀도와 재현율의 산술 평균으로 계산된다.(O / X)
6. ROC 곡선은 이진 분류 모델의 성능을 시각화하는 도구이다. 이때 X축과 Y축에 해당하는 값으로 올바르게 짝지어진 것은?
 - a. X축: Recall, Y축: Precision
 - b. X축: TNR, Y축: TPR
 - c. X축: Precision, Y축: Recall
 - d. X축: FPR , Y축: TPR
7. FPR(False Positive Rate)을 특이성(Specificity, TNR)을 이용한 수식으로 표현하시오.

답:

8. 다음 코드를 실행했을 때 custom_predict의 결과 배열로 올바른 것은?

```
proba = [[0.3], [0.51], [0.49], [0.9]]  
binarizer = Binarizer(threshold=0.5)  
custom_predict = binarizer.fit_transform(proba)
```

- a. [[0], [1], [1], [1]]
- b. [[0], [0], [0], [1]]
- c. [[1], [1], [0], [1]]
- d. [[0], [1], [0], [1]]

9. XGBoost와 LightGBM은 모두 GBM 기반의 알고리즘이다. 다음중 LightGBM이 XGBoost에 비해 갖는 장점으로 가장 적절한 것은?

- a. GPU 가속을 지원하지 않는다.
- b. 균형 트리 분할(Level-wise) 방식을 사용하여 과적합에 더 강하다.
- c. 리프 중심 트리 분할(Leaf-wise) 방식을 사용하여 학습 속도가 훨씬 빠르다.
- d. 작은 데이터 세트(1,000건 이하)에서 특히 성능이 좋다.

10. 결정 트리 모델에서 과적합(Overfitting)을 막기 위한 파라미터 튜닝 방법으로 틀린 것은?

- a. max_depth 값을 증가시킨다.
- b. min_samples_leaf 값을 증가시킨다.
- c. max_features 값을 줄인다.
- d. min_samples_split 값을 증가시킨다.

11. LightGBM의 '리프 중심 분할(Leaf-wise)' 방식은 트리의 균형을 맞추지 않고

손실(Loss)을 가장 많이 줄일 수 있는 리프 노드를 지속적으로 분할한다. 이 방식이 균형 트리 분할(Level-wise) 대비 가지는 이론적 단점과, 이를 제어하기 위해 반드시 튜닝해야 하는 파라미터는?

- a. 단점: 트리가 너무 얕아져서 편향이 높아진다. / 필수 튜닝: min_data_in_leaf
- b. 단점: 학습 속도가 느려진다. / 필수 튜닝: learning_rate
- c. 단점: 메모리 사용량이 급증한다. / 필수 튜닝: num_leaves
- d. 단점: 트리의 깊이가 매우 깊어져 과적합될 수 있다. / 필수 튜닝: max_depth

12. 스택킹(Stacking) 앙상블을 구현할 때, CV(Cross Validation) 기반의 스택킹을 수행하지 않고, 단순히 학습 데이터로 메타 모델을 학습시킬 경우 발생하는 치명적인 문제로 가장 적절한 것은?

- a. 데이터 누수에 의한 과적합
- b. 편향 증가
- c. 연산 속도 저하
- d. 과소적합(Underfitting)

13. 다음 파이썬 코드에서 GridSearchCV가 수행하는 총 학습(fit) 횟수는?

```
param_grid = {'max_depth': [2, 4, 6], 'min_samples_split': [2, 3]}  
rf_clf = RandomForestClassifier(n_estimators=10)  
grid_cv = GridSearchCV(rf_clf, param_grid, cv=5)  
grid_cv.fit(X_train, y_train)
```

답:

14. SMOTE를 적용했을 때 일반적으로 나타나는 성능 지표의 변화 추세로 가장 적절한 것은?

- a. 정확도(Accuracy)가 100%에 가까워진다.
- b. 정밀도와 재현율이 모두 비약적으로 상승한다.
- c. 재현율(Recall)은 높아지지만, 정밀도(Precision)는 다소 낮아질 수 있다.
- d. 정밀도는(Precision)는 높아지지만, 재현율(Recall)은 다소 낮아질 수 있다.

15. CV 세트 기반의 스택킹(Stacking) 모델을 구축하려고 한다.

- 전체 학습 데이터 건수: 10,000건
- 최종 테스트 데이터 건수: 2,000건
- 기반 모델(Base Model): 3개 (RandomForest, XGBoost, LightGBM)
- 교차 검증(CV) 폴드 수: 5개

이때, 최종 메타 모델이 학습하기 위해 입력받는 학습용 피쳐 데이터셋의 정확한 행렬 크기(Shape)는?

답: