

ML세션 5주차 문제

범위: 파이썬 머신러닝 완벽 가이드 7장

1. GMM 군집화는 K-Means와 달리 개별 데이터 포인트가 특정 군집에 속할 확률을 0과 1 사이의 값으로 제공하는 'Soft Clustering'을 지원한다. (O / X)
2. K-Means 알고리즘에서 Centroid의 이동이 더 이상 발생하지 않으면, 개별 데이터 포인트의 군집 소속 변경 가능성과 관계없이 알고리즘이 종료된다. (O / X)
3. 실루엣 계수(Silhouette Coefficient)가 1에 가까울수록 해당 데이터 포인트는 인접한 다른 군집과 멀리 떨어져 있음을 의미하며, -1에 가까운 값은 해당 데이터가 아예 잘못된 군집에 할당되었음을 의미한다. (O / X)
4. 평균 이동 군집화는 데이터가 모여 있는 밀도가 가장 높은 곳으로 중심을 이동시키기 위해 KDE를 이용하며, 대역폭 h가 클수록 추정된 확률 밀도 함수는 좁고 뽕족한 형태를 띤다. (O / X)
5. K-Means는 거리 기반 알고리즘이므로, 데이터 세트의 속성별 단위가 다를 경우 군집화 효율을 높이기 위해 피처를 재조정하는 StandardScaler 적용이 권장된다. (O / X)
6. 실루엣 분석의 수식 에 대한 설명 중 가장 적절한 것은?

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

- a. $a(i)$ 는 i 번째 데이터 포인트가 속한 군집 내 다른 데이터 포인트들과의 거리의 합이다.
- b. $b(i)$ 는 i 번째 데이터 포인트에서 가장 가까운 타 군집 내 데이터 포인트들까지의 거리의 합이다.
- c. 분모인 $\max(a(i), b(i))$ 는 실루엣 계수 값을 -1에서 1 사이로 정규화하기 위한 장치이다.
- d. 특정 데이터의 실루엣 계수가 음수라면, 해당 데이터가 속한 군집 내의 평균 거리($a(i)$)보다 가장 가까운 타 군집과의 평균 거리($b(i)$)가 더 크다는 뜻이다.

7. DBSCAN의 포인트 정의에 대한 설명 중 옳은 것을 모두 고르시오.

(가) 입실론 주변 영역 내에 최소 데이터 개수 이상의 타 데이터를 가지고 있는 경우를 핵심 포인트(Core Point)라 한다

(나) 자신은 최소 데이터 개수를 충족하지 못하지만, 핵심 포인트를 이웃 포인트로 가지고 있는 경우를 경계 포인트(Border Point)라 한다

(다) 사이킷런의 min_samples파라미터는 자기 자신을 제외한 이웃 데이터의 최소 개수를 의미한다.

(라) 핵심 포인트도 아니고 핵심 포인트를 이웃으로 가지지도 않는 데이터는 잡음 포인트(Noise Point)로 분류된다

8. 다음 중 군집화 알고리즘과 그 특징이 잘못 연결된 것은?

- a. Mean Shift - 데이터의 밀도가 가장 높은 곳으로 중심을 이동하며 군집의 개수를 미리 정할 필요가 없다.
- b. GMM - 데이터 세트가 길쭉한 타원형으로 늘어선 경우 K-Means보다 효과적인 군집화가 가능하다.
- c. DBSCAN - 기하학적으로 복잡한 데이터 분포(예: 내부 원과 외부 원 형태)에서도 효과적인 군집화가 가능하다.
- d. K-Means - 이상치에 강건하며 데이터 양이 많아져도 수행 시간이 크게 늘어나지 않는 장점이 있다

9. K-평균(K-Means) 알고리즘에서 초기 군집 중심점을 설정할 때, 임의의 위치 대신 데이터 포인트 간의 거리를 고려하여 첫 번째 중심점에서 멀리 떨어진 포인트를 다음 중심점으로 선택할 확률을 높이는 초기화 방식의 명칭은?

답:

10. make_blobs() API에서 cluster_std 파라미터 값이 커질수록 나타나는 현상으로 옳은 것은?

- a. 데이터 포인트들이 군집 중심점에 더 밀집되어 분포한다.
- b. 데이터 포인트들이 군집 중심점에서 더 넓게 퍼져서 분포한다.
- c. 생성되는 전체 데이터 레코드의 개수가 늘어난다.
- d. 생성되는 피쳐(Feature)의 개수가 늘어난다.

11. KMeans클래스를 사용하여 군집화를 완료한 후, 시각화를 위해 각 군집 중심점의 좌표 정보를 확인하고자 할 때 참조해야 하는 속성명은?

답:

12. 실루엣 분석에서 특정 데이터 i 에 대해 $a(i) = 0.2$ 이고 $b(i) = 0.1$ 인 상황이 발생했다면, 이 데이터의 군집화 상태에 대한 설명으로 옳은 것은?

- a. 현재 속한 군집 내에서 데이터들이 매우 조밀하게 뭉쳐 있다.
- b. 해당 데이터 포인트는 아예 다른 군집에 잘못 할당되었을 가능성이 매우 높다.
- c. 인접한 다른 군집과의 거리가 충분히 멀어 이상적인 군집화 상태이다.
- d. 전체 실루엣 평균값이 높다면 이 개별 수치는 무시해도 좋다.

13. GMM 군집화에서 개별 가우시안 분포의 평균, 분산 및 데이터가 특정 분포에 속할 확률을 추정하기 위해 사용되는 모수 추정 방법의 명칭은?

답:

14. DBSCAN의 파라미터 조절과 노이즈(Noise) 데이터의 상관관계에 대한 설명으로 옳은 것은?

- a. eps값을 작게 하면 노이즈 데이터의 개수가 줄어든다.
- b. min_samples 값을 크게 하면 노이즈 데이터의 개수가 늘어난다.
- c. min_samples를 크게 할수록 군집화의 범위가 더 넓어진다.
- d. eps 값을 크게 하면 데이터 밀도가 낮아져 노이즈 인식이 강화된다.

15. 고객 세그멘테이션의 RFM 기법 중, '고객이 얼마나 자주 상품을 구매했는가'를 나타내며 고객의 충성도를 측정하는 지표로 사용되는 것은?

- a. Recency
- b. Frequency
- c. Monetary Value
- d. Loyalty Value

16. Mean Shift 군집화 코드에서 사용자가 일일이 설정하기 어려운 최적의 bandwidth 값을 데이터 분포에 기반하여 계산해주는 함수의 이름은?

답: `estimate_bandwidth()`

17. 판다스를 활용한 RFM 가공 과정에서, CustomerID로 그룹화한 후 여러 컬럼에 대해 서로 다른 집계 함수(예: max, count, sum)를 한 번에 적용하기 위해 사용되는 메서드로 가장 알맞은 것은?

- a. `apply()`
- b. `transform()`
- c. `agg()`
- d. `map()`